

1. 概述

本文档记录了在 Qwen3-4B-Instruct-2507 模型上进行的五组实验，旨在验证以下假设：

Transformer 模型的中间层存在一个 语言无关的语义空间（**interlingua**），该空间编码的是“含义”而非“表面形式”。

实验设计参考了 David Ng 的博客文章 *"LLM Neuroanatomy III: Do LLMs Break the Sapir-Whorf Hypothesis?"*。

pagebreak

2. 实验一：多语言 Sapir-Whorf 测试

2.1. 方法

- 数据：8 个常识事实 × 5 种语言（英/中/德/法/日）× 2 种句式（陈述/疑问）= 80 条 prompt
- 指标：逐层计算余弦相似度
 - ▶ **RED**：同一事实，不同语言（如 EN“sun rises” ↔ ZH“太阳升起”）
 - ▶ **GREEN**：同一语言，不同事实（如 EN“sun rises” ↔ EN“water boils”）
 - ▶ **BLUE**：不同事实，不同语言（基线）

2.2. 核心曲线




Figure 1: RED/GREEN/BLUE 余弦相似度曲线（陈述句）




Figure 2: 中心化余弦相似度（减去 BLUE 基线）

2.3. 结果

层范围	主导因素
L0-L5	GREEN > RED → 语言占主导
L6-L22	RED > GREEN → 语义占主导（interlingua 出现！）
L23-L35	GREEN > RED → 语言回归（输出准备）

- RED > GREEN 的层数：17/37（46%）
- 峰值 RED-GREEN 差距：约 +0.21

2.4. 聚类图




Figure 3: PCA 按话题聚类——陈述句，全部 37 层




Figure 4: PCA 按话题聚类——疑问句，全部 37 层

2.5. 结论

即使是在 4B 规模的指令模型上，也存在三层结构：输入层处理语言 → 中间层编码语义 → 输出层回归语言。与博客中 7B–72B 指令模型相比，效应较弱但模式一致。说明 *interlingua* 是预训练的自然涌现属性，指令微调仅起到放大作用。

pagebreak

3. 实验二：句法变换测试

3.1. 方法

- 数据：8 个事实 × 6 种句法形式 = 48 条 prompt，仅英语
 - plain / inverted / cleft / emphatic / impersonal / topicalized
- 可视化：PCA 图中 颜色 = 话题，形状 = 句法结构

3.2. 核心图表




Figure 5: PCA：颜色 = 话题，形状 = 句法结构——全部 37 层




Figure 6: 句法 RGB 曲线：RED = 同话题不同句法，GREEN = 同句法不同话题

3.3. 结果

- 全层平均相似度：句法变化 **0.81**（最高 = 最不敏感）
- L13-L18：句法变化 **0.80**

3.4. 结论

句法结构对模型的中间层表示 几乎没有影响。同一事实无论用什么句法表达，向量都高度聚类。语法形式已被模型压缩。

pagebreak

4. 实验三：语用模式测试

4.1. 方法

- 数据：8 个事实 × 3 种语用模式（陈述/疑问/命令）× 4 种变体 = 96 条 prompt
- 可视化：PCA 图中 颜色 = 话题，形状 = 语用模式

4.2. 核心图表



Figure 7: PCA：颜色 = 话题，形状 = 语用模式——全部 37 层




Figure 8: 语用 RGB 曲线：RED = 同话题不同模式，GREEN = 同模式不同话题




Figure 9: 各模式内话题聚类对比：陈述 vs 疑问 vs 命令

4.3. 结果

对比维度	L13-L18 相似度	全层平均
句法变化	0.80	0.81
语用模式变化	0.58	0.58
语言变化	0.68	0.58

4.4. 结论

语用模式造成的表示差异 远大于 句法变化（0.58 vs 0.81），且与语言差异（0.58）大小相当。“提问”vs“陈述”vs“命令”是一种更深层的语义信号，模型不会将其与句法形式一同压缩。疑问句的特殊性不在于语言形式，而在于其承载的 语用行动（请求回答）。

pagebreak

5. 实验四：迭代生成测试

5.1. 方法

- 初始 prompt → 生成 → 用生成结果作为新 prompt → 重复 20 次
- 追踪各层连续迭代间的余弦相似度

5.2. 核心图表




Figure 10: 连续迭代相似度——各层对比




Figure 11: 与原始 prompt 的偏离度——各层对比

5.3. 结果

层	连续相似度	含义
emb	0.03	词元层面完全发散
L0-L5	0.37→0.50	编码阶段，逐渐稳定
L6-L23	0.45-0.57	活跃处理，差异最大
L24-L34	0.57→0.79	收敛到稳定主旨
L35	0.46	输出投射，强制选择 token

5.4. 结论

最稳定的层是 **L30-L34**（后期层），而非中间层。中间层（**L6-L23**）变化最大——它们在做“工作”（处理具体措辞和细节）。后期层将细节压缩，回归到稳定的核心语义。

pagebreak

6. 实验五：多话题迭代聚类测试

6.1. 方法

- 8 个话题 × 5 次迭代 = 40 个向量
- PCA 降维，颜色标记话题

6.2. 核心图表




Figure 12: PCA 按话题聚类——全部 37 层，8 话题 × 5 迭代




Figure 13: 话题内 vs 跨话题相似度——各层对比

6.3. 结果

层	话题内相似度	跨话题相似度	差距
---	--------	--------	----

L10	0.51	0.29	0.21
L11	0.53	0.30	0.23
L12	0.53	0.31	0.22
L30	0.71	0.58	0.13
L34	0.83	0.76	0.07

6.4. 结论

中层（L10–L12）话题内/跨话题 差距最大（0.22），说明中层最能区分不同话题。后期层话题内相似度最高（0.83）但跨话题相似度也很高（0.76），差距缩小——后期层压缩了话题间的差异，趋向普适表示。

pagebreak

7. 综合结论

7.1. 模型的层状处理管线

L0–L5: 输入编码 — 词元 → 初步表示
 L6–L12: 语言处理 — 剥离语言特定特征
 L13–L18: 语义提取 — 语言被擦除，话题开始聚类（SW 效应）
 L19–L29: 细节加工 — 处理具体措辞和阐述
 L30–L34: 主旨压缩 — 压缩细节，回归稳定核心语义（迭代稳定性最高）
 L35: 输出投射 — 强制选择下一个 token

7.2. 影响语义空间的三个层次

因素	相似度	影响程度
句法结构（plain vs cleft vs inverted...）	0.80	几乎无影响
语用模式（陈述 vs 疑问 vs 命令）	0.58	显著影响
语言（英语 vs 中文 vs 德语...）	0.58	显著影响

7.3. 与博客的差异

博客使用的 7B–72B 指令模型显示约 25 层 RED > GREEN，而我们的 4B 指令模型仅 17 层。差距来自模型规模——interlingua 随规模增长而增强，4B 模型已展现该结构但不够强。

7.4. 核心发现

语言不影响思想（Sapir-Whorf 假说在 LLM 中被推翻）。
 但 语用意图（问/说/命令）是一种比语言本身更深刻的语义信号。
 模型在 后期层而非中间层 达到最大表示稳定性——“意义空间”是一个压缩过程的结果，而非一个静态的存储层。